Les données du projet

TSYP14 · Track 2 · Équipe IA · contenu du dossier 1_Data · 27/10/2026

En bref : toutes les données utilisées par les modèles et l'arène, rangées en 5 sous-dossiers. Les modèles lisent leurs fichiers ici (chemins relatifs `../1_Data/…`), il n'y a donc plus de copie en double dans les dossiers des modèles.

```
1_Data/
  USCRN/            uscrn_clean.parquet (+ scripts de téléchargement et de nettoyage, rapport qualité)
  ERA5_USCRN/       era5_uscrn_hourly_2022_2025.csv
  Voisins/scan/     5 stations SCAN voisines + liste_scan.csv (+ download_voisins.py)
  Attaques_IA_v2/   nos attaques réalistes multi-capteurs : seed1 … seed16 + générateur + README
  Attaques_cyber/   repo1_attack-002/ · repo2_attack-engine/ · release_officielle/ · release_multivariable/
                    + Note_equipe_cyber_attaques.pdf
```

1. Base propre : USCRN (stations au sol)

Mesures horaires 2022–2025 (35 064 heures par station) du réseau américain USCRN, 6 stations aux climats contrastés. La cible de l'attaque est l'humidité du sol à 5 cm (`SOIL_MOISTURE_5`, m³/m³, résolution 0,001). Les autres colonnes servent de contexte : humidité 10/20/50/100 cm, pluie `P_CALC` (mm, résolution 0,1), températures de l'air et du sol, rayonnement, humidité de l'air.

Station	Lat / Lon	Climat	Sondes 20/50 cm	Rôle
AZ_Tucson_11_W	32,24 / −111,17	désert	non	évaluée
CA_Fallbrook_5_NE	33,44 / −117,19	méditerranéen	non	évaluée
MS_Newton_5_ENE	32,34 / −89,07	humide subtropical	oui	évaluée
NY_Ithaca_13_E	42,44 / −76,25	continental (gel)	oui	évaluée
OK_Goodwell_2_SE	36,57 / −101,61	semi-aride	oui	évaluée
OK_Goodwell_2_E	36,60 / −101,59	semi-aride	oui (92 %)	voisine de Goodwell 2 SE (≈ 3 km)

Nettoyage (`clean_uscrn.py`) : codes de valeur manquante → valeurs manquantes explicites, drapeaux qualité appliqués, bornes physiques, continuité horaire vérifiée, incohérences entre profondeurs signalées (`flag_incoherence_verticale`, jamais donné aux détecteurs). Les trous restent des trous (aucune imputation).

2. Contexte externe : ERA5 et stations voisines

Source	Variables	Usage
ERA5 (réanalyse, maille ~25 km), horaire 2022–2025	t2m, d2m (température et point de rosée), tp_mm (pluie), ssrd (rayonnement), swvl1 (humidité du sol 0–7 cm), stl1 (température du sol)	référence externe que l'attaquant ne contrôle pas (jumeaux ERA5, plausibilité de la pluie)
SCAN (USDA), 5 stations à 80–130 km	pluie horaire (PRCP), humidité du sol 5 cm (SMS-2)	pluie régionale et tendance d'humidité pour Tucson, Newton, Ithaca

Station suivie	Voisine SCAN	Distance
AZ_Tucson_11_W	Walnut Gulch #1 (2026:AZ)	119 km
MS_Newton_5_ENE	Livingston-UWA (2114:AL) · Dee River Ranch (2174:AL) · Starkville (2064:MS)	87 · 110 · 129 km
NY_Ithaca_13_E	Geneva #1 (2011:NY)	80 km

3. Nos attaques réalistes : Attaques_IA_v2

Générées par l'équipe IA (`generateur_attaques_realistes.py`) sur la base propre. L'attaquant contrôle la station et modifie **ensemble** 5 cm, 10 cm et pluie de façon physiquement crédible ; les autres capteurs restent vrais. 16 tirages (seeds), 304 attaques par seed (≈ 15 % des heures), partitions train 2022–23 · validation 2024 · test 2025.

Famille	Falsifié	Construction	Durée
fake_storm	5 + 10 cm + pluie	vrai orage de la même station/saison transplanté sur une période sèche	36–96 h
hidden_storm	5 + 10 cm + pluie	vrai orage effacé ; le sol suit une vraie courbe de séchage	≤ 240 h
smooth_bias	5 + 10 cm	décalage ±0,01–0,06 qui monte et redescend doucement ; 10 cm amorti et retardé	24–240 h
drift	5 + 10 cm	rampe lente puis retour	48–300 h
replay	5 + 10 cm + pluie	copie d'une période 7–60 jours avant, raccordée sans saut	12–120 h
stealth_era5	5 + 10 cm	petit décalage ±0,004–0,015 qui suit l'anomalie ERA5	24–200 h

Version corrigée. La v1 avait des artefacts (décimales en trop, séchage artificiel, valeurs écrêtées à 0,005) qui gonflaient les scores (une règle « décimales » seule donnait F1 0,78). La v2 arrondit à la résolution réelle, copie de vrais séchages et **rejette** au lieu d'écrêter. Contrôle : aucune statistique simple ne distingue les heures attaquées des heures normales. Fichiers par seed : `detector_input` (sans label), `row_labels`, `cell_labels`, `attack_manifest`, `clean_reference` (évaluateurs seulement).

3 bis. Le générateur en détail

Script `generateur_attaques_realistes.py SEED DOSSIER` : lit la base propre + ERA5, place les attaques **station par station et année par année** (par station et par an : 3 fake_storm, 2 hidden_storm, 2 smooth_bias, 2 drift, 2 replay, 2 stealth_era5 ; jusqu'à 600 essais chacun), puis écrit les 5 fichiers du format cyber.

Famille	Construction exacte (tirages aléatoires du seed)
fake_storm	source = un vrai début de pluie (≥ 1 mm après ≥ 24 h sec) de la même station, saison ± 60 jours ; cible = une période sèche sans pluie ; on ajoute à la cible les **variations** 5 cm / 10 cm de la source et sa pluie, sur 36–96 h
hidden_storm	cible = un vrai début d'orage ; on cherche une vraie période sèche de 10 jours qui démarre au même niveau d'humidité (± 0,02) et à la même saison (± 45 j) ; la pluie est mise à 0 et le sol suit cette courbe de séchage jusqu'à ce qu'elle repasse sous la vraie valeur (≤ 240 h)
smooth_bias	amplitude ±0,01–0,06 m³/m³ (ou ±5–25 % du niveau moyen) ; montée et descente exponentielles (constantes 2–12 h et 4–24 h) ; durée 24–240 h
drift	même amplitude ; rampe linéaire sur toute la durée (48–300 h) puis retour en 12–48 h
10 cm (biais, dérive)	même forme, **retardée de 2–8 h et atténuée × 0,4–0,9** : l'eau met du temps à descendre, une copie identique serait suspecte
replay	copie de la même station 7–60 jours avant (5 cm, 10 cm, pluie), décalée pour partir du niveau actuel, fondu de 6 h à l'entrée et à la sortie ; 12–120 h
stealth_era5	décalage ±0,004–0,015 dont la forme suit l'anomalie ERA5 (humidité ERA5 moins sa moyenne de la semaine précédente) ; 10 cm × 0,6 ; 24–200 h

Règle commune	Détail
Pas de chevauchement	12 h de marge entre deux attaques, 48 h loin des bords, aucune valeur manquante dans la fenêtre
Résolution réelle	5/10 cm arrondis à 0,001 m³/m³, pluie à 0,1 mm
Plage de la station	si une valeur sort du min/max observé de la station → tentative **rejetée** (jamais écrêtée)
Labels exacts	une cellule n'est labellisée attaquée que si sa valeur a réellement changé (row_labels, cell_labels par colonne)

4. Les livraisons de l'équipe cyber : Attaques_cyber

Dossier	Contenu	Labels	Remarques
repo1_attack-002	biais courts +0,02–0,08 sur la 5 cm, 2024–2025 (CSV par station et année)	oui	sauts nets ; utilisé par le One-Class
repo2_attack-engine	spike ±0,30, biais ±0,15, dérive, replay sur la 5 cm, 2022–2025	oui	valeurs écrêtées à 0 ; utilisé par le One-Class
release_officielle	release officielle (run seed14, 22/10) : spike, bias, drift, replay, stealth sur la 5 cm ; detector_input + ground_truth + manifest + contrat	oui (test réservé à l'évaluateur)	548 valeurs attaquées à exactement 0, biais toujours ±0,050 ; utilisée par le supervisé final (2022–24) et pour le test indépendant (2025)

Dossier	Contenu	Labels	Remarques
release_multivariable	5 cm + 10 cm + pluie attaqués	train + validation seulement	pluie constante +2 mm/h, pluie en rampe, 10 cm qui saute à la même heure

5. Qui utilise quoi

	USCRN	ERA5	Voisins	Attaques_IA_v2	Cyber repo 1 + 2	Release officielle
One-Class (2_)	oui	oui	—	test seulement	oui (seuil 2024, test 2025)	test seulement
Supervisé (3_)	via les jeux	oui	oui	seeds 1–8 (2022–24) + test 2025 des 16 seeds	—	2022–24 (apprentissage) + test 2025
Arène (4_)	base propre	oui	oui	—	—	—

Règle commune : l'heure `time` est la fin de l'intervalle en UTC ; l'année d'une heure = année de (time − 1 h) ; 2025 n'est jamais utilisé pour apprendre.

6. Nos choix et pourquoi

Notre choix	Pourquoi	Alternative écartée (et pourquoi)
6 stations aux climats contrastés (désert → gel)	un détecteur qui marche partout, pas réglé sur un climat	1 seule station : résultats non généralisables
Horaire 2022–2025, sans imputation	c'est la résolution des attaques ; un trou imputé crée de fausses régularités	données journalières : spikes et replays courts invisibles
ERA5 + voisins SCAN comme références	l'attaquant contrôle la station, pas la réanalyse ni les stations à 80–130 km	NASA POWER : journalier seulement (gardé de côté)
Découpage par année : 2025 = test	une attaque et son contexte restent du même côté ; reproduit « une année future »	découpage aléatoire par heure : fuite entre heures voisines
Attaques multi-capteurs (5 + 10 cm + pluie)	un vrai attaquant qui contrôle l'enregistreur falsifie tout ce qui le trahirait	5 cm seule : la 10 cm la dénonce trivialement, score trop optimiste
Rejeter au lieu d'écrêter, arrondir	supprime les artefacts que la v1 laissait (F1 0,78 avec une simple règle « décimales »)	écrêtage (v1) : valeurs collées au bord, faciles à repérer
16 seeds	mesurer la stabilité (écart entre seeds) et garder 8 seeds jamais vus pour le test	1 seul tirage : un score chanceux passe inaperçu