Modèle One-Class hybride

TSYP14 · Track 2 « Ground Truth Under Attack » · Équipe IA · rapport détaillé · 27/10/2026

En bref : un détecteur qui apprend **uniquement le comportement normal** (aucune attaque vue à l'apprentissage) et signale ce qui s'en écarte. Sur les attaques des deux dépôts de l'équipe cyber (test 2025) : **F1 0,72**, précision 0,64, rappel 0,82, **105/114 attaques détectées**. Il est faible sur les attaques multi-capteurs réalistes (F1 0,05) et n'améliore pas le modèle supervisé quand on les combine : **il est gardé comme « second avis »** dans l'interface, pas dans l'alerte finale.

1. Principe

Un modèle One-Class n'a jamais besoin d'exemples d'attaques : il apprend ce qu'est une station **normale** (2022–2023), puis tout ce qui sort de cette normalité est suspect. Avantage : il peut signaler une attaque **jamais vue**. Limite : il signale aussi les événements naturels rares (forte pluie, gel, panne), donc plus de fausses alertes qu'un modèle supervisé.

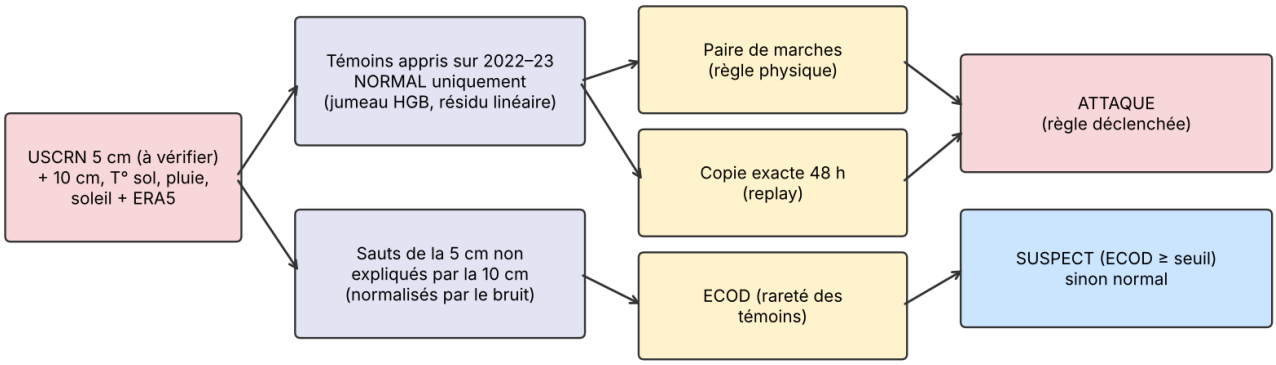
Période	Rôle	Attaques utilisées ?
2022–2023	apprentissage du normal (jumeaux, bruit, référence ECOD)	non (valeurs propres)
2024	choix des seuils (F1 max avec au plus 5 % de fausses alertes)	oui, seulement pour le seuil
2025	test final, une seule fois	oui, seulement pour le score

2. Données

Les attaques des **deux dépôts de l'équipe cyber**, combinées sans chevauchement (une attaque du dépôt 1 qui touche une heure déjà attaquée par le dépôt 2 est retirée entière). Seule la sonde **5 cm** est attaquée dans ces jeux. Base : USCRN horaire nettoyé (5 stations) + ERA5 horaire.

Jeu	Attaques	Fichier (dans 1_Data/Attaques_cyber)
Dépôt 1 « attack-002 »	biais courts +0,02 à +0,08 m³/m³ (6–72 h)	repo1_attack-002/*_2024.csv, *_2025.csv
Dépôt 2 « attack-engine »	spike ±0,30, biais ±0,15 (~130 h), dérive (rampe ±0,12), replay	repo2_attack-engine/uscrn_attacked.parquet
Test 2025	114 attaques (94 biais courts, 5 biais, 5 dérives, 5 replays, 5 spikes)	—

3. Le pipeline



Brique	Ce qu'elle fait
Résidu linéaire	$sm5 \approx \alpha + \beta_1 \cdot sm10 + \beta_2 \cdot ERA5$ (par station, appris sur le normal)
Jumeau numérique	HistGradientBoosting (300 arbres) par station : prédit la 5 cm à partir de la 10 cm, ERA5, pluie, températures, saison — sans jamais voir la 5 cm
Écart à la référence	résidus comparés à leur médiane des 14 jours précédents (décalée de 4 jours pour ne pas absorber l'attaque), normalisés par station

Brique	Ce qu'elle fait
Paire de marches → ATTAQUE	saut de la 5 cm non expliqué par la 10 cm (|z| > 4), suivi dans ≤ 140 h d'un saut inverse de taille comparable (rapport 0,6–1,6), avec un plateau décalé par rapport au jumeau
Copie exacte → ATTAQUE	une séquence de 48 h identique à une séquence déjà vue (replay)
ECOD → SUSPECT	rareté conjointe des témoins par rapport à 20 000 heures normales (probabilités de queue empiriques)

4. Modèles comparés (test 2025, mêmes données)

Modèle	F1	Précision	Rappel	Fausses alertes	PR-AUC	Attaques détectées
HYBRIDE (marches + copie + ECOD)	0,72	0,64	0,82	7,4 %	0,61	105/114
Paire de marches (physique)	0,67	0,59	0,80	9,1 %	0,67	108/114
ECOD	0,58	0,53	0,63	9,2 %	0,60	104/114
ENSEMBLE (7 modèles, Fisher)	0,55	0,59	0,52	5,9 %	0,51	78/114
kNN (distance)	0,55	0,54	0,56	7,8 %	0,53	83/114
One-Class SVM	0,54	0,54	0,55	7,6 %	0,45	80/114
Covariance robuste (MCD)	0,54	0,51	0,58	9,0 %	0,49	108/114
Référence : résidu seul (Détecteur v2, étape a)	0,54	0,59	0,50	5,6 %	0,63	68/114
LOF	0,54	0,54	0,54	7,3 %	0,51	78/114
Jumeau numérique (HGB)	0,53	0,55	0,52	7,0 %	0,51	73/114
PCA (reconstruction)	0,51	0,52	0,50	7,3 %	0,43	98/114
Replay : copie exacte	0,12	0,99	0,06	0,0 %	0,19	4/114

Par type (hybride) : biais courts 91/94, biais 5/5, spikes 5/5, replays 4/5, dérives 0/5 en ATTAQUE — les 5 dérives sont signalées au niveau SUSPECT (ECOD).

Niveau	Vraiment attaqué (test 2025)	Action conseillée
ATTAQUE	64 % des heures	rejeter / isoler la donnée
SUSPECT	19 % des heures	vérifier (souvent une dérive lente)
normal	1,3 % des heures	accepter

5. Test sur d'autres jeux (honnêteté)

Jeu de test 2025	One-Class hybride	Commentaire
Dépôts cyber 1 + 2 (ci-dessus)	F1 0,72	attaques brusques sur la 5 cm : ses règles sont faites pour ça
Release officielle cyber (5 cm)	F1 0,52 · précision 0,50 · rappel 0,54 · fausses alertes 2,8 %	le supervisé fait 0,72–0,73 sur ce jeu
Nos attaques réalistes multi-capteurs	F1 0,05	l'attaquant falsifie 5 cm + 10 cm + pluie ensemble : la 10 cm ne « dénonce » plus rien

Tentative d'amélioration (One-Class v2) : même principe (apprend le normal seulement), mais sur les témoins du détecteur v3 (capteurs non attaqués, incréments, changements de moyenne ; Isolation Forest par station, seuil = budget de 2 % de fausses alertes). Résultat : **0,31** sur nos attaques multi-capteurs (contre 0,05) mais **0,34** sur la release cyber (contre 0,52). Aucune version ne gagne partout ; la v1 est conservée (meilleure sur les attaques simples).

6. Faut-il l'ajouter au supervisé ?

Test 2025	Supervisé seul	Supervisé OU One-Class (alerte confirmée)	Supervisé OU One-Class (avec SUSPECT)
Release cyber	F1 0,72 · fausses alertes 0,3 %	F1 0,64 · 3,1 %	F1 0,41 · 10,9 %
Nos attaques (16 seeds)	F1 0,62 · 1,1 %	F1 0,59 · 3,4 %	F1 0,52 · 10,1 %

Test « attaque inconnue » (une famille retirée de l'entraînement du supervisé, rappel à 2 % de fausses alertes) : le supervisé sans la famille détecte encore hidden storm 76 %, smooth bias 36 %, replay 34 %, drift 17 % ; le One-Class v2 fait mieux seulement sur les **faux orages inconnus** (29 % contre 10 %).

Décision : le One-Class reste un **second avis** (affiché dans l'interface et l'arène pour l'enquête), pas une source d'alerte : l'ajouter à l'alerte multiplie les fausses alertes par 3 à 10 pour très peu d'attaques en plus.

6 bis. Nos choix et pourquoi

Notre choix	Pourquoi	Alternative écartée (et pourquoi)
Apprendre seulement le normal (2022–2023)	peut signaler une attaque jamais vue ; aucune dépendance au style d'un attaquant	supervisé seul : aveugle aux familles absentes de l'apprentissage
Hybride : 3 spécialistes au lieu d'un modèle	chaque attaque a sa signature : marche (biais), copie (replay), rareté globale (dérive) ; hybride F1 0,72	meilleur modèle unique ECOD 0,58 ; ensemble de 7 modèles (Fisher) 0,55
Règle « paire de marches » (physique)	un biais court = un saut de la 5 cm non suivi par la 10 cm, puis un saut inverse ; très précis (F1 0,68 seule)	seuil sur le saut seul : chaque averse donne un saut
ECOD pour le niveau SUSPECT	sans paramètre, rapide, explicable témoin par témoin (probabilités de queue)	Isolation Forest, One-Class SVM, LOF, kNN, MCD, PCA : F1 0,51–0,55, moins lisibles
Référence décalée de 4 jours (14 jours glissants)	une attaque de quelques jours n'est pas absorbée par sa propre référence	référence centrée : l'attaque devient « normale » pour elle-même
Seuils sur 2024, ≤ 5 % de fausses alertes	2025 reste le test ; budget de fausses alertes réaliste pour un opérateur	maximiser le F1 sans contrainte : trop de fausses alertes
3 niveaux (normal / SUSPECT / ATTAQUE)	les dérives lentes sont vues mais incertaines : on les signale sans bloquer	alerte binaire : on perdrait les 5 dérives ou on doublerait les fausses alertes
Garder la v1 (pas la v2)	aucune version ne gagne partout ; v1 meilleure sur les attaques cyber	v2 sur les témoins du v3 : 0,31 nous / 0,34 cyber
Second avis, pas alerte	combiné à l'alerte : fausses alertes × 3 à × 10 pour très peu d'attaques en plus	alerte = supervisé OU One-Class

7. Utilisation

Entrée (une ligne par station et par heure)	Sortie
time, station, SOIL_MOISTURE_5, SOIL_MOISTURE_10, SOIL_TEMP_5, T_HR_AVG, P_CALC, SOLARAD + ERA5 (t2m, tp_mm, swvl1, stl1), au moins ~18 jours d'historique, sans label	score, alerte (0/1), niveau (normal / SUSPECT / ATTAQUE), raison en clair

```
from detector import HybridDetector
det = HybridDetector("models/oneclass_hybride_v5.joblib")
out = det.predict(df)          # df = USCRN + ERA5 fusionnés par station et heure
```

Fichier du dossier	Rôle
models/oneclass_hybride_v5.joblib	le modèle (jumeaux, référence ECOD, réglages des règles, seuils)
detector.py	code de prédiction (HybridDetector)
Notebook_OneClass.ipynb	apprentissage complet + comparaison des 12 modèles (exécuté, résultats inclus)
resultats_oneclass_v5_combine.csv · predictions_oneclass_2025.csv	résultats du notebook
requirements.txt · README.md	versions et mode d'emploi

8. Limites

• Entraîné sur 5 stations : une nouvelle station demande de ré-entraîner (2 ans de données propres).

• Les règles visent des attaques brusques ; un attaquant prudent (rampes douces, 5 cm + 10 cm ensemble) passe.

• Les dérives lentes ne sont signalées qu'au niveau SUSPECT.

• Testé sur des attaques générées par les programmes de l'équipe cyber ; un jeu de test indépendant figé reste à obtenir.