Modèle supervisé — détecteur v3

TSYP14 · Track 2 · Équipe IA · modèle final retenu · rapport détaillé · 27/10/2026

En bref : le modèle final apprend sur nos attaques réalistes multi-capteurs **et** sur la release officielle de l'équipe cyber. Sur l'année **2025, jamais utilisée pour apprendre ni pour régler le seuil** : **F1 0,726** sur la release cyber (précision 0,87, fausses alertes 0,5 %) et **F1 0,639 ± 0,04** sur nos attaques (16 tirages, précision 0,85, fausses alertes 1,7 %). Point de départ honnête : 0,447 avec 24 % de fausses alertes.

Version (test 2025)	Nos attaques F1	Release cyber F1	Fausses alertes (nos attaques)
Modèle envoyé avant (8 seeds, rotation)	0,447	0,66*	24 %
v3 — appris sur nos attaques seulement (16 seeds)	0,669	–	2,1 %
v3 — appris sur la release cyber seulement	–	0,723	–
v3 final — les deux ensemble (retenu)	**0,639**	**0,726**	1,7 %

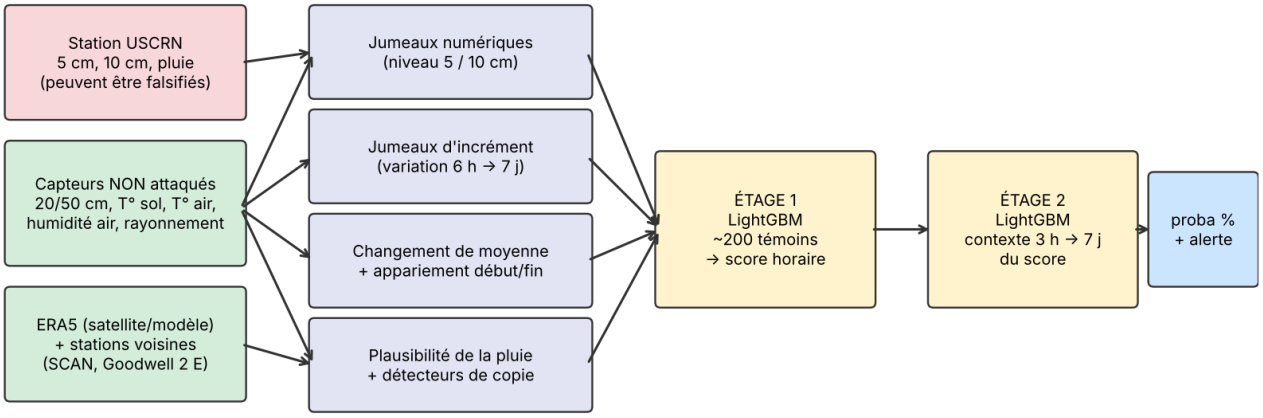
* meilleur modèle précédent sur la release cyber (One-Class / règles). Le modèle final perd 0,03 sur nos attaques mais garde le niveau cyber avec **un seul modèle** qui connaît les deux styles d'attaque (multi-capteurs réalistes et attaques brusques sur la 5 cm) : c'est le plus robuste pour un jeu de test inconnu.

1. Données et protocole

Base : USCRN horaire nettoyé 2022–2025, 6 stations (Tucson AZ, Fallbrook CA, Newton MS, Ithaca NY, Goodwell OK ×2) ; ERA5 horaire ; voisins SCAN. **Attaques** : (a) notre générateur v2 corrigé (sans artefact), 16 tirages × 304 attaques ≈ 15 % des heures, 5 cm + 10 cm + pluie falsifiés ensemble ; (b) release officielle cyber (spike, bias, drift, replay, stealth sur la 5 cm). Détails : *Donnees.pdf*.

Règle	Comment
Apprentissage	années 2022–2024 seulement ; nos seeds 1–8 + release cyber (poids ×4 → la cyber pèse 1/3 du total)
Test	2025 de la release cyber + 2025 de nos 16 seeds ; les seeds 9–16 n'ont jamais été vus (même pas leurs années 2022–24)
Seuil	choisi sur des prédictions hors-échantillon par année (on apprend sur 2 ans, on prédit le 3e) ; seuil = 0,474 ; 2025 n'intervient jamais
Heures cyber « non évaluables »	exclues de l'apprentissage et du score, comme le demande la release

2. Le pipeline



Idée : l'attaquant peut falsifier 5 cm + 10 cm + pluie ENSEMBLE, mais pas le reste du monde physique.
Les témoins mesurent l'écart entre ce que la station dit et ce que les capteurs non attaqués impliquent.

Idée clé : l'attaquant contrôle 5 cm, 10 cm et la pluie, mais **pas le reste du monde physique** (capteurs profonds, températures du sol, humidité de l'air, rayonnement, ERA5, voisins). Chaque **témoin** mesure un désaccord entre ce que la station déclare et ce que ces sources impliquent.

Groupe de témoins (209 au total)	Ce que ça mesure	Attaques visées
Jumeaux de niveau (tw5, tu5, tu10, tE5, tE10)	LightGBM par station qui prédit 5/10 cm ; appris par année sur les heures normales des autres années ; tu* = capteurs non attaqués seulement	toutes
Jumeaux auto-calibrés (xw5, xu5, xu10)	mêmes jumeaux appris par mois sur toutes les heures, sans étiquette, perte robuste (Huber)	biais, dérive ; moins de fausses alertes
Jumeaux d'incrément (inc, pair)	prédisent la VARIATION sur 6 h / 24 h / 72 h / 7 j	biais, dérive
Changement de moyenne (box)	moyenne d'une fenêtre 1–10 j comparée aux fenêtres avant / après, sur les résidus	biais, dérive, stealth
Plausibilité de la pluie	classifieur « il pleut ? » (humidité de l'air, rayonnement, T°, ERA5, voisins)	faux / orages cachés
Copies exactes	même suite de variations 5+10 cm ou de pluie déjà vue ailleurs dans la série	replay, orages
Voisins, profondeurs, sauts	pluie SCAN, Goodwell 2 E ; rapports 5/10 et 10/20 cm ; sauts ; corrélation 5↔10 cm	toutes, spikes

Étage 1 : LightGBM (600 arbres, 63 feuilles, 200 obs. min.) → un score par heure. **Étage 2** : LightGBM (300 arbres) qui relit ce score sur des fenêtres de 3 h à 7 jours (moyenne, max, avant / après, niveau relatif au mois) : une attaque dure des heures ou des jours, l'étage 2 bouche les trous et supprime les alertes isolées. **Sortie** : probabilité 0–1 par heure + alerte si ≥ 0,474.

3. Détail technique

Les jumeaux numériques (LightGBM régression, 300 arbres, 31 feuilles, pas 0,05) prédisent ce que la sonde devrait mesurer ; le **résidu** (mesure − prédiction) est la base des témoins.

Jumeau	Cible	Entrées	Apprentissage
tw5	5 cm	10 cm et ses variations, pluie station et ERA5 (6–72 h), humidité ERA5, T° sol 5 cm, air, rayonnement, heure, saison	par année (« laisser une année de côté ») sur les heures **normales labellisées** 2022–24
tu5 · tu10	5 · 10 cm	**uniquement des capteurs non attaqués** : 20/50 cm, T° sol 5/10/20 cm, air, humidité de l'air, rayonnement, ERA5, voisins	idem
tE5 · tE10	5 · 10 cm	ERA5 seul (humidité, T°, pluie 6–168 h)	idem
xw5 · xu5 · xu10	5 · 10 cm	comme tw5 / tu5 / tu10	par mois (6 plis), **toutes les heures, sans label**, perte robuste Huber → s'adapte à l'année surveillée
inc5 / inc10 (k = 6, 24, 72, 168 h)	variation sur k h	valeur k h avant + pluie, rayonnement, T°, ERA5, voisins, capteurs non attaqués sur la même fenêtre	par année, sur des fenêtres entièrement normales

Famille de témoins	Calcul
Normalisation de chaque résidu	z = résidu / écart-type du normal ; *dev* = z − médiane de 4 à 18 jours avant ; *cdev* = z − médiane centrée 30 jours ; moyennes 6–168 h, écart-type 24 h, pente 72 h
Paire montée / descente	max(montée inexpliquée dans la semaine passée, descente inexpliquée dans la semaine suivante) — début et fin d'un biais
Changement de moyenne (box)	moyenne d'une fenêtre L ∈ {24, 72, 168, 240 h} moins la moyenne de ses deux flancs, sur tu, xu, tE et les rapports entre profondeurs
Plausibilité de la pluie	LightGBM « il pleut ? » (200 arbres) depuis humidité de l'air, rayonnement relatif, T°, ERA5, voisins ; puis pluie sans support, support sans pluie, montée du sol sans pluie possible (24–72 h)
Copies exactes	24 h de variations 5 + 10 cm identiques (≥ 10 non nulles) vues ≥ 72 h plus tôt ; 12 h de pluie identiques ; 48 h de valeurs 5 cm identiques
Sauts et cohérence	saut de la 5 cm non expliqué par la 10 cm (normalisé par le MAD), corrélation 24 h des variations 5↔10 cm, log(5/10 cm), log(10/20 cm), voisin Goodwell 2 E

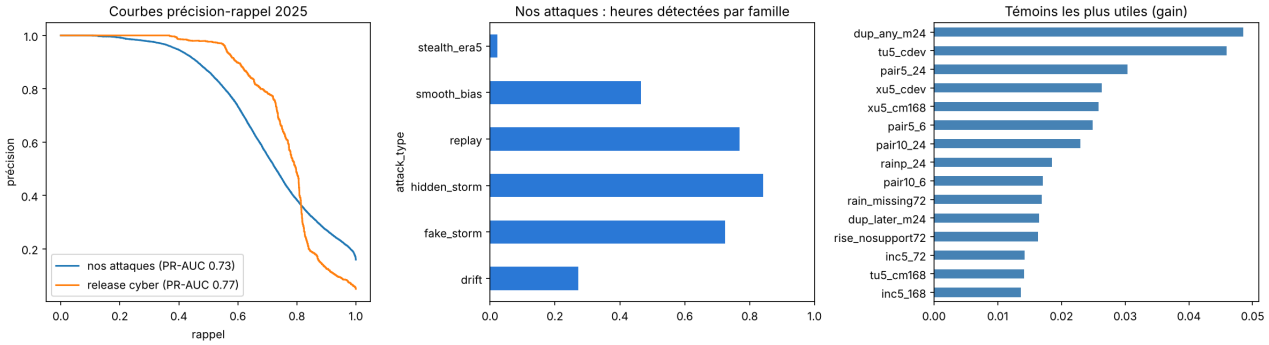
Étape	Réglages
Étage 1	LightGBM binaire, 600 tours, 63 feuilles, ≥ 200 heures par feuille, 70 % des lignes et 50 % des témoins par arbre, L2 = 2
Étage 2	LightGBM 300 tours, 31 feuilles ; entrées : score p1, moyennes et max sur 3/6/12/24/48/96/168 h (centrées), quantile 25 % (≥ 24 h), moyenne 24 h avant / après, p1 relatif à sa médiane 30 jours + 10 témoins clés

Étape	Réglages
Hors-échantillon	les deux étages sont appris 3 fois en laissant de côté 2022, 2023 puis 2024 → un score « jamais vu » pour chaque heure 2022–24 ; l'étage 2 apprend sur ces scores-là (pas sur des scores trop optimistes)
Poids	heures cyber × (nb d'heures à nous / nb d'heures cyber / 2) → la release cyber pèse 1/3 de l'apprentissage
Seuil	400 seuils candidats ; on garde celui qui maximise le F1 pondéré hors-échantillon 2022–24 → 0,474
Mémoire	1,56 M d'heures × 209 témoins : matrice float32 pré-allouée (fichier disque), sous-ensembles LightGBM sans copie → tient dans 8 Go

4. Résultats 2025

Indicateur (test 2025)	Release cyber	Nos attaques (moyenne ± écart, 16 seeds)
F1	0,726	0,639 ± 0,038
Précision	0,87	0,85 ± 0,04
Rappel (heures attaquées trouvées)	0,62	0,51 ± 0,04
Fausses alertes (heures normales signalées)	0,5 %	1,7 %
PR-AUC (1 = parfait, hasard ≈ 0,15)	0,77	0,73
Attaques détectées (≥ 1 heure en alerte)	–	63 %

Nos seeds 1–8 (leurs attaques 2022–24 ont servi à apprendre) : F1 0,651 · seeds 9–16 (jamais vus) : **F1 0,626** — l'écart est faible, le modèle ne récite pas les attaques vues.



Famille (nos attaques)	Heures détectées	Attaques détectées
drift	27 %	56 %
fake_storm	72 %	88 %
hidden_storm	84 %	68 %
replay	77 %	77 %
smooth_bias	46 %	66 %
stealth_era5	2 %	8 %

Release cyber, attaques détectées (≥ 1 h) : bias 62 %, drift 100 %, replay 65 %, spike 99 %, stealth 0 %.

Station	F1 (16 seeds)	PR-AUC
AZ_Tucson_11_W	0,562	0,676
CA_Fallbrook_5_NE	0,693	0,828
MS_Newton_5_ENE	0,668	0,759
NY_Ithaca_13_E	0,645	0,745
OK_Goodwell_2_SE	0,548	0,646

5. Contrôles de robustesse

Variante (v3, nos attaques, 8 seeds)	F1	Précision	Rappel	Fausses alertes	PR-AUC
Complet (deux étages)	0,664	0,82	0,56	2,4 %	0,74
Étage 1 seul + lissage 3 h	0,648	0,75	0,57	3,5 %	0,72
Sans détecteurs de copie	0,632	0,78	0,53	2,7 %	0,71

Variante (v3, nos attaques, 8 seeds)	F1	Précision	Rappel	Fausses alertes	PR-AUC
Sans copie ni jumeaux auto-calibrés (le plus prudent)	0,622	0,83	0,50	1,9 %	0,72

Attaque inconnue (une famille retirée de l'apprentissage, rappel à 2 % de fausses alertes) : le modèle détecte encore hidden storm 76 %, smooth bias 36 %, replay 34 %, drift 17 % de la famille jamais vue. **One-Class en plus ?** Supervisé OU One-Class : cyber 0,72 → 0,64, fausses alertes ×3 à ×10 → le One-Class reste un **second avis**, pas une source d'alerte (voir *Rapport_OneClass.pdf*).

6. Historique des versions

Version	Ce qui a changé	Résultat (test 2025)
v1 (25/10)	attaques v1 + validation par rotation	F1 0,73 annoncé… mais gonflé par les artefacts du générateur v1
v1 honnête	même modèle sur les attaques v2 corrigées	F1 0,447 · 24 % de fausses alertes
v3 étape 1	témoins des capteurs non attaqués + copies exactes	F1 0,479 · 5,5 %
v3 étape 2	+ jumeaux d'incrément	F1 0,513 · 6,5 %
v3 étape 3	+ changement de moyenne, jumeaux auto-calibrés, deux étages	F1 0,664 (8 seeds) · 0,669 (16 seeds) · 2,1 %
v3 final	+ release officielle cyber dans l'apprentissage (1/3), seuil commun	**0,639 nos attaques · 0,726 cyber · 1,7 %**

7. Nos choix et pourquoi

Notre choix	Pourquoi	Alternative écartée (et pourquoi)
LightGBM (arbres de gradient)	données tabulaires, 1,5 M d'heures, valeurs manquantes gérées nativement, rapide, importance des témoins lisible	réseau de séquences (LSTM / Transformer) : long à entraîner, peu d'attaques par station, peu explicable
Témoins physiques plutôt que valeurs brutes	l'attaquant falsifie 5/10 cm/pluie mais pas le reste : on mesure les désaccords	donner les séries brutes : le modèle apprend le style du générateur
Jumeaux sur capteurs non attaqués (tu)	la 10 cm et la pluie sont falsifiées aussi : un jumeau 5 cm ← 10 cm serait trompé	approche du One-Class (5 cm comparée à la 10 cm) : F1 0,05 sur nos attaques
Jumeaux auto-calibrés par mois, sans label	s'adaptent au niveau de l'année surveillée ; apport mesuré +0,01 F1 (0,622 → 0,632, variantes sans copies)	uniquement par année : biais de niveau d'une année à l'autre
Deux étages	une attaque dure des heures à des jours : l'étage 2 lit le contexte (+0,016 F1, fausses alertes 3,5 → 2,4 %)	lissage simple du score sur 3 h
Validation « une année de côté »	imite l'usage réel (année future) ; pas de fuite entre heures voisines	validation aléatoire par heure ou rotation (v1) : optimiste
Un seul modèle pour nos attaques + cyber	un seul seuil, connaît les deux styles ; perd 0,03 chez nous, garde 0,73 cyber	deux modèles séparés : il faudrait savoir à l'avance quel attaquant on affronte
Seuil sur hors-échantillon 2022–24	2025 reste un vrai test jamais touché	seuil choisi sur 2025 : score gonflé
One-Class en second avis	le combiner à l'alerte multiplie les fausses alertes par 3 à 10	alerte = supervisé OU One-Class
F1 par heure comme métrique principale	c'est la métrique du challenge ; on rapporte aussi PR-AUC, fausses alertes, attaques détectées	taux d'attaques détectées seul : cache les fausses alertes

8. Limites

• **Mode lot** : pour juger une heure, le modèle regarde jusqu'à ~7 jours après. En exploitation : score provisoire immédiat, jugement définitif après une semaine.

• **Jumeaux auto-calibrés** : apprennent sur l'année surveillée, sans étiquette (comme une normalisation) ; sans eux F1 ≈ 0,62.

• **stealth** (±0,004–0,015 m³/m³) : quasi indétectable, c'est la taille du bruit naturel. **drift** lent : ~1/4 des heures, mais plus de la moitié des dérives repérées au moins une fois.

• Les attaques viennent de notre générateur et de la release cyber : un jeu de test indépendant reste le juge final.

9. Dossier et utilisation

Fichier	Rôle
Notebook_detecteur_v3.ipynb	notebook complet exécuté : données → témoins → étage 1 → étage 2 → seuil → test 2025 → sauvegarde
detecteur_v3.py	construction des témoins (build) + prédiction (predict) ; à garder à côté du notebook
detecteur_v3_final.joblib	modèle entraîné (étages 1 et 2, liste des témoins, seuil 0,474)
predictions_2025_nos_attaques.parquet · resultats_2025.png	sorties du test 2025

```
import joblib, detecteur_v3 as det
M = joblib.load("detecteur_v3_final.joblib")
D = det.build("dossier")      # dossier = detector_input.parquet + row_labels.parquet (format cyber)
D = det.predict(D, M)         # ajoute proba (0-1) et alerte (0/1) par station et par heure
```

Entrée : une ligne par station et par heure (5/10/20/50/100 cm, températures du sol, air, humidité, pluie, rayonnement) + ERA5 + voisins depuis *1_Data* ; au moins quelques semaines d'historique par station.